



Aprendizagem Automática



João Paulo Pordeus Gomes



Métodos Estadísticos

Aula Anterior

- ▶ Histogramas e distribuições
- ▶ Distribuição Gaussiana
- ▶ Regra de Bayes



Classificadores Estatísticos

Classificação

- ▶ Observar uma série de características de uma instância e determinar a classe a qual este pertence



Classificação

- ▶ Observar uma série de **características** de uma instância e determinar a **classe** a qual este pertence



Classificação

- ▶ Observar uma série de **características (x)** de uma instância e determinar a **classe (c)** a qual este pertence



Classificação

- ▶ Observar uma série de **características (x)** de uma instância e determinar a **classe (c)** a qual este pertence
- ▶ $p(c|x)$



Classificação

- ▶ Observar uma série de **características (x)** de uma instância e determinar a **classe (c)** a qual este pertence
- ▶ $p(c|x) = p(x|c)p(c) / p(x)$



Classificação

- ▶ Caso com duas classes (c_1 e c_2)



Classificação

- ▶ Caso com duas classes (c_1 e c_2)
 - ▶ $p(c_1|x) = p(x|c_1)p(c_1) / p(x)$
 - ▶ $p(c_2|x) = p(x|c_2)p(c_2) / p(x)$



Classificação

- ▶ Caso com duas classes (c_1 e c_2)
 - ▶ $p(c_1|x) = p(x|c_1)p(c_1) / p(x)$
 - ▶ $p(c_2|x) = p(x|c_2)p(c_2) / p(x)$
- ▶ Para classificar, escolhe o mais provável



Classificação

- ▶ Caso com duas classes (c_1 e c_2)
 - ▶ $p(c_1|x) = p(x|c_1)p(c_1) / p(x)$
 - ▶ $p(c_2|x) = p(x|c_2)p(c_2) / p(x)$



Classificação

- ▶ Caso com duas classes (c_1 e c_2)
 - ▶ $p(c_1|x) \propto p(x|c_1)p(c_1)$
 - ▶ $p(c_2|x) \propto p(x|c_2)p(c_2)$




Classificação

- ▶ Caso com duas classes (c_1 e c_2)
 - ▶ $p(c_1|x) \propto p(x|c_1)p(c_1)$
 - ▶ $p(c_2|x) \propto p(x|c_2)p(c_2)$
- ▶ Estimar $p(c_2)$, $p(c_1)$, $p(x|c_2)$ e $p(x|c_1)$ a partir do conjunto de treino




Classificação

- ▶ Caso com duas classes (c_1 e c_2)
 - ▶ $p(c_1|x) \propto p(x|c_1)p(c_1)$
 - ▶ $p(c_2|x) \propto p(x|c_2)p(c_2)$
- ▶ Estimar $p(c_2)$, $p(c_1)$, $p(x|c_2)$ e $p(x|c_1)$ a partir do conjunto de treino




Classificação

- ▶ $p(c_2)$ e $p(c_1)$




Classificação

- ▶ $p(c_2)$ e $p(c_1)$
 - ▶ Classes equiprováveis
 - ▶ Proporcional ao número de exemplos
 - ▶ Conhecido




Classificação

- ▶ $p(x|c_2)$ e $p(x|c_1)$




Classificação

- ▶ $p(x|c_2)$ e $p(x|c_1)$
 - ▶ Supõe que os dados são Gaussianos




Classificação

- ▶ $p(x|c_2)$ e $p(x|c_1)$
 - ▶ Supõe que os dados são Gaussianos
 - ▶ Estima os parâmetros da distribuição




Classificação

- ▶ $p(x|c_2)$ e $p(x|c_1)$
 - ▶ Supõe que os dados são Gaussianos
 - ▶ Estima os parâmetros da distribuição
 - ▶ Calcula $p(x|c_2)$ e $p(x|c_1)$



Classificação

- ▶ Para cada classe
 - ▶ $p(c) = n_c / N$ ou $p(c) = 0.5$




Classificação

- ▶ Para cada classe

- ▶ $p(c) = n_c / N$ ou $p(c) = 0.5$


- ▶ Calcula

- ▶ $\mu_c = \frac{1}{n} \sum_{i=1}^n x_i$ e $\Sigma_c = \frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)(x_i - \mu)^T$



Classificação


- ▶ Quando se deseja classificar



Classificação

- ▶ Quando se deseja classificar
- ▶ Para cada classe

- ▶
$$p(\mathbf{x}|c) = \frac{1}{|\Sigma|^{1/2}(2\pi)^{m/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_c)^T \Sigma^{-1}_c (\mathbf{x} - \boldsymbol{\mu}_c)\right)$$




Classificação

► Quando se deseja classificar

► Para cada classe

►
$$p(\mathbf{x}|\mathbf{c}) = \frac{1}{|\Sigma|^{1/2}(2\pi)^{m/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_c)^T \Sigma^{-1}_c (\mathbf{x} - \boldsymbol{\mu}_c)\right)$$

►
$$p(\mathbf{c}|\mathbf{x}) \propto p(\mathbf{x}|\mathbf{c})p(\mathbf{c})$$




Classificação

► Quando se deseja classificar

► Para cada classe

- $p(\mathbf{x}|\mathbf{c}) = \frac{1}{|\Sigma|^{1/2}(2\pi)^{m/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_c)^T \Sigma^{-1}_c (\mathbf{x} - \boldsymbol{\mu}_c)\right)$
- $p(\mathbf{c}|\mathbf{x}) \propto p(\mathbf{x}|\mathbf{c})p(\mathbf{c})$
- Escolhe o mais provável






Análise do Classificador Gaussiano


Classificação

► $p(c|x) \propto p(x|c)p(c)$




Classificação

► $p(c|x) \propto p(x|c)p(c)$




Classificação

► $p(c|x) \propto p(x|c)p(c)$



Classificação

► $p(c|x) \propto p(x|c)p(c)$



Discriminante
Quadrático
Gaussiano

Discriminante Quadrático Gaussiano

- ▶ $p(c|x) \propto p(x|c)p(c)$
- ▶ Dados distribuídos segundo uma gaussiana
 - ▶ $\mu_c = \frac{1}{n} \sum_{i=1}^n x_i$
 - ▶ $\Sigma_c = \frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)(x_i - \mu)^T$



Matriz de Covariância

- ▶ $\Sigma_c = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^T$
- ▶ Para um vetor de dimensão 2 a matriz é 2x2
 - ▶ $\Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix}$




Matriz de Covariância

- ▶ $\Sigma_c = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^T$
- ▶ Para um vetor de dimensão 2 a matriz é 2x2
 - ▶ $\Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix}$
 - ▶ Valores altos de σ_{12}




Matriz de Covariância

- ▶ $\Sigma_c = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^T$
- ▶ Para um vetor de dimensão 2 a matriz é 2x2
 - ▶ $\Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix}$
 - ▶ Valores altos de σ_{12}



Matriz de Covariância

- ▶ $\Sigma_c = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^T$
- ▶ Para um vetor de dimensão 2 a matriz é 2x2
 - ▶ $\Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix}$
 - ▶ Valores altos de σ_{12}




Matriz de Covariância

- ▶ $\Sigma_c = \frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)(x_i - \mu)^T$
- ▶ Para um vetor de dimensão 2 a matriz é 2x2
 - ▶ $\Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix}$
 - ▶ Valores de σ_{12} próximos de 0




Matriz de Covariância

- ▶ $\Sigma_c = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^T$
- ▶ Para um vetor de dimensão 2 a matriz é 2x2
 - ▶ $\Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix}$
 - ▶ Valores de σ_{12} próximos de 0



Matriz de Covariância

- ▶ $\Sigma_c = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^T$
- ▶ Para um vetor de dimensão 2 a matriz é 2x2
 - ▶ $\Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix}$
 - ▶ Valores de σ_{12} próximos de 0



Naive Bayes Gaussiano

- ▶ Considera que as variáveis não tem correlação
- ▶ Matriz de covariância diagonal


- ▶ $\Sigma = \begin{bmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{bmatrix}$



Naive Bayes Gaussiano

- ▶ Considera que as variáveis não tem correlação
- ▶ Matriz de covariância diagonal


- ▶ $\Sigma = \begin{bmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{bmatrix}$



Naive Bayes Gaussiano

- ▶ Considera que as variáveis não tem correlação
- ▶ Matriz de covariância diagonal

- ▶ $\Sigma = \begin{bmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{bmatrix}$



Naive Bayes – Formulação Geral

Naive Bayes

- ▶ Formulação Geral

- ▶ $p(c|\mathbf{x}) \propto p(\mathbf{x}|c)p(c)$



Naive Bayes

- ▶ Formulação Geral

- ▶ $p(c|\mathbf{x}) \propto p(\mathbf{x}|c)p(c)$

- ▶ $\mathbf{x} = [x_1 \quad \dots \quad x_n]$



Naive Bayes

- ▶ Formulação Geral

- ▶ $p(c|\mathbf{x}) \propto p(\mathbf{x}|c)p(c)$

- ▶ $\mathbf{x} = [x_1 \quad \dots \quad x_n]$

- ▶ Como $x_1 \perp x_2 \perp \dots \perp x_n$. Podemos reescrever

- ▶ $p(c|\mathbf{x}) \propto p(x_1|c)p(x_2|c) \dots p(x_n|c)p(c)$



Naive Bayes

- ▶ Formulação Geral

- ▶ $p(c|\mathbf{x}) \propto p(\mathbf{x}|c)p(c)$

- ▶ $\mathbf{x} = [x_1 \quad \dots \quad x_n]$

- ▶ Como $x_1 \perp x_2 \perp \dots \perp x_n$. Podemos reescrever

- ▶ $p(c|\mathbf{x}) \propto p(x_1|c)p(x_2|c) \dots p(x_n|c)p(c)$

- ▶ $p(c|\mathbf{x}) \propto p(c) \prod_{i=1}^n p(x_i|c)$





Dúvidas ?