



Aprendizado Automático



João Paulo Pordeus Gomes

Redução de Dimensionalidade

Classificação e Regressão

- ▶ Diversos problemas reais têm muitos atributos
 - ▶ Reconhecimento de faces
 - ▶ Classificação de textos
 - ▶ Reconhecimento de impressões digitais
 - ▶ ...



Classificação e Regressão

- ▶ Diversos problemas reais têm muitos atributos
 - ▶ Reconhecimento de faces
 - ▶ Classificação de textos
 - ▶ Reconhecimento de impressões digitais
 - ▶ ...
- ▶ Overfitting



Classificação e Regressão

- ▶ Diversos problemas reais têm muitos atributos
 - ▶ Reconhecimento de faces
 - ▶ Classificação de textos
 - ▶ Reconhecimento de impressões digitais
 - ▶ ...
- ▶ Overfitting
- ▶ Custo computacional
- ▶ Custo de armazenamento



Redução de Dimensionalidade

- ▶ Duas estratégias mais comuns
 - ▶ Seleção de atributos
 - ▶ Combinação de atributos



Seleção de atributos

- ▶ **Duas abordagens**

- ▶ Usar algum critério para definir o quão bom é um atributo (Filter)
- ▶ Selecionar subgrupos de atributos e ver o resultado na classificação/regressão (Wrapper)



Filter

- ▶ Fisher Score


- ▶ Toma cada um dos atributos e calcula

$$V(i) = \frac{(\mu_{(+)}(i) - \mu_{(-)}(i))^2}{\sigma_{(+)}^2(i) + \sigma_{(-)}^2(i)}$$



Filter

- ▶ Fisher Score



Wrapper

- ▶ Problema de otimização combinatória
- ▶ Escolher um subconjunto das variáveis originais que fornece o melhor resultado para classificação



Wrapper

- ▶ Problema de otimização combinatória
- ▶ Escolher um subconjunto das variáveis originais que fornece o melhor resultado para classificação
- ▶ Pode utilizar uma estratégia gulosa (*greedy*)



Combinação de atributos

- ▶ Combinar os atributos originais de forma a transformá-los em vetores de atributos de menor dimensão
- ▶ Como combinar ?
 - ▶ Linearmente
 - ▶ Não linearmente
- ▶ Qual critério usar para combinar ?




Análise de Componentes Principais

- ▶ Principal Component Analysis (PCA)
- ▶ Método de combinação linear dos atributos para a geração de novos atributos.
- ▶ Redução de dimensão se dá pela seleção de um subgrupo destes atributos



PCA

► Idéia



PCA

- ▶ $Ax = x'$
- ▶ Vamos definir u como uma parte de A



PCA

- ▶ $Ax = x'$
- ▶ Vamos definir u como uma parte de A
- ▶ Temos que encontrar u , tal que:
 - ▶ $\sigma^2 = \frac{1}{N-1} \sum_{i=1}^N (x' - \mu) (x' - \mu)^T$
- ▶ Seja o maior possível



PCA

- ▶ $Ax = x'$
- ▶ Vamos definir u como uma parte de A
- ▶ Temos que encontrar u , tal que:
 - ▶ $\sigma^2 = \frac{1}{N-1} \sum_{i=1}^N (x' - \mu) (x' - \mu)^T$
- ▶ Seja o maior possível
- ▶ Sob certas restrições
- ▶ $u^t u = 1$



PCA

$$\blacktriangleright \max \frac{1}{N-1} \sum_{i=1}^N (x' - \mu) (x' - \mu)^T$$

s.t

$$\blacktriangleright u^t u = 1$$



PCA

$$\blacktriangleright \max \frac{1}{N-1} \sum_{i=1}^N (x') (x')^T$$

s.t

$$\blacktriangleright u^t u = 1$$



PCA

$$\blacktriangleright \max \frac{1}{N-1} \sum_{i=1}^N (x') (x')^T$$

s.t

$$\blacktriangleright u^t u = 1$$

▶ Como:

$$\blacktriangleright \max \frac{1}{N-1} \sum_{i=1}^N (x') (x')^T$$

$$\blacktriangleright = \max \frac{1}{N-1} \sum_{i=1}^N (ux) (ux)^T$$



PCA

$$\blacktriangleright \max \frac{1}{N-1} \sum_{i=1}^N (x') (x')^T$$

s.t

$$\blacktriangleright u^t u = 1$$

▶ Como:

$$\blacktriangleright \max \frac{1}{N-1} \sum_{i=1}^N (x') (x')^T$$

$$\blacktriangleright = \max \frac{1}{N-1} \sum_{i=1}^N (ux) (ux)^T$$

$$\blacktriangleright = \max u^T \sum u$$



PCA

► $\max u^T \Sigma u$

s.t

► $u^t u = 1$



PCA

► $\max u^T \Sigma u$

s.t

► $u^t u = 1$

► Multiplicadores de Lagrange



PCA

► $\max u^T \Sigma u$

s.t

► $u^t u = 1$

► Multiplicadores de Lagrange

► $L = u^T \Sigma u - \lambda(u^t u - 1)$



PCA

► $\max u^T \Sigma u$

s.t

► $u^t u = 1$

► Multiplicadores de Lagrange

► $L = u^T \Sigma u - \lambda(u^t u - 1)$

► $\frac{\partial L}{\partial u} = 0$

► $\frac{\partial L}{\partial \lambda} = 0$



PCA

► $\max u^T \Sigma u$

s.t

► $u^t u = 1$

► Multiplicadores de Lagrange

► $L = u^T \Sigma u - \lambda(u^t u - 1)$

► $\Sigma u = \lambda u$

► $u^t u = 1$



PCA

- ▶ Como resolver

- ▶ $\Sigma u = \lambda u$



PCA

- ▶ Como resolver
 - ▶ $\Sigma u = \lambda u$
- ▶ Problema de Autovetores e autovalores



PCA

- ▶ Como resolver
 - ▶ $\Sigma u = \lambda u$
- ▶ Problema de Autovetores e autovalores
- ▶ Para achar u , basta calcular os autovetores da matriz Σ
- ▶ λ são os autovalores associados
- ▶ Os autovalores correspondem a variância explicada em cada novo atributo



PCA na prática

- ▶ Toma os dados de entrada
- ▶ Subtrai as médias
- ▶ Calcula a matriz de covariância
- ▶ Calcula os autovalores e autovetores
- ▶ Escolhe os k maiores autovalores
- ▶ Utiliza os k autovetores correspondentes para criar k novos atributos





Dúvidas ?