



Aprendizagem Automática



João Paulo Pordeus Gomes

Regressão Linear Univariada

Regressão Linear

- ▶ Explicar uma determinada variável de saída (y) através de variáveis de entrada (x), utilizando um modelo linear.



Regressão Linear

- ▶ Explicar uma determinada variável de saída (y) através de variáveis de entrada (x), utilizando um modelo linear.
- ▶ Exemplo
 - ▶ Concessão de crédito



Regressão Linear

► Concessão de Crédito

Salário (R\$)	Crédito (R\$)
1500	16500
2000	18000
3000	28000
3300	33000
4200	49000
...	...
5500	52000



Regressão Linear

► Concessão de Crédito

- Encontrar uma relação linear entre Salário e Credito

Salário (R\$)	Crédito (R\$)
1500	16500
2000	18000
3000	28000
3300	33000
4200	49000
...	...
5500	52000



Regressão Linear

► Concessão de Crédito

- Encontrar uma relação linear entre Salário e Credito
- Salário (x_i) e Crédito (y_i)

Salário (R\$)	Crédito (R\$)
1500	16500
2000	18000
3000	28000
3300	33000
4200	49000
...	...
5500	52000



Regressão Linear

► Concessão de Crédito


- Encontrar uma relação linear entre Salário e Credito
- Salário (x_i) e Crédito (y_i)
- $\bar{y}_i = w_1 x_i + w_0$

Salário (R\$)	Crédito (R\$)
1500	16500
2000	18000
3000	28000
3300	33000
4200	49000
...	...
5500	52000




Regressão Linear

► $\bar{y}_i = w_1 x_i + w_0$




Regressão Linear

► $\bar{y}_i = w_1 x_i + w_0$



Regressão Linear

► $\bar{y}_i = w_1 x_i + w_0$



Regressão Linear

- ▶ $\bar{y}_i = w_1 x_i + w_0$
- ▶ $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n e_i^2$
 - ▶ Onde: $e_i = y_i - \bar{y}_i$



Regressão Linear

- ▶ $\bar{y}_i = w_1 x_i + w_0$
- ▶ $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n e_i^2$
 - ▶ Onde: $e_i = y_i - \bar{y}_i$
- ▶ $\min_{w_1 w_0} J(w_1, w_0)$



Regressão Linear

- ▶ $\bar{y}_i = w_1 x_i + w_0$
- ▶ $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n e_i^2$
 - ▶ Onde: $e_i = y_i - \bar{y}_i$
- ▶ $\min_{w_1 w_0} J(w_1, w_0)$
 - ▶ $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - \bar{y}_i)^2$




Regressão Linear

- ▶ $\bar{y}_i = w_1 x_i + w_0$
- ▶ $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n e_i^2$
 - ▶ Onde: $e_i = y_i - \bar{y}_i$
- ▶ $\min_{w_1 w_0} J(w_1, w_0)$
 - ▶ $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - \bar{y}_i)^2$
 - ▶ $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - w_1 x_i - w_0)^2$




Regressão Linear

►
$$J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - w_1 x_i - w_0)^2$$




Regressão Linear

- ▶ $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - w_1 x_i - w_0)^2$
 - ▶ Método do gradiente descendente




Gradiente Descendente

- ▶ Inicializar os pontos de forma aleatória
 - ▶ w_1, w_0
- ▶ Movimento os pontos para a direção que diminui J



Gradiente Descendente

- ▶ Inicializar os pontos de forma aleatória
 - ▶ w_1, w_0
- ▶ Movimento os pontos para a direção que diminui J
 - ▶ $w = w - \alpha \frac{\partial J}{\partial w}$



Gradiente Descendente

- ▶ $w = w - \alpha \frac{\partial J}{\partial w}$
- ▶ $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - w_1 x_i - w_0)^2$



Gradiente Descendente

- ▶ $w = w - \alpha \frac{\partial J}{\partial w}$
- ▶ $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - w_1 x_i - w_0)^2$
- ▶ $\frac{\partial J}{\partial w_0} = ?$



Gradiente Descendente

- ▶ $w = w - \alpha \frac{\partial J}{\partial w}$
- ▶ $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - w_1 x_i - w_0)^2$
- ▶ $\frac{\partial J}{\partial w_0} = [\frac{1}{2n} 2 \sum_{i=1}^n (y_i - w_1 x_i - w_0)](-1)$



Gradiente Descendente

- ▶ $w = w - \alpha \frac{\partial J}{\partial w}$
- ▶ $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - w_1 x_i - w_0)^2$
- ▶ $\frac{\partial J}{\partial w_0} = [\frac{1}{2n} 2 \sum_{i=1}^n e_i](-1)$



Gradiente Descendente

- ▶ $w = w - \alpha \frac{\partial J}{\partial w}$
- ▶ $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - w_1 x_i - w_0)^2$
- ▶ $\frac{\partial J}{\partial w_0} = [\frac{1}{2n} 2 \sum_{i=1}^n e_i](-1)$
 - ▶ $w_0 = w_0 + \alpha \frac{1}{n} \sum_{i=1}^n e_i$



Gradiente Descendente

- ▶ $w = w - \alpha \frac{\partial J}{\partial w}$
- ▶ $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - w_1 x_i - w_0)^2$
- ▶ $\frac{\partial J}{\partial w_0} = [\frac{1}{2n} 2 \sum_{i=1}^n e_i](-1)$
 - ▶ $w_0 = w_0 + \alpha \frac{1}{n} \sum_{i=1}^n e_i$
- ▶ $\frac{\partial J}{\partial w_1} = ?$



Gradiente Descendente

- ▶ $w = w - \alpha \frac{\partial J}{\partial w}$
- ▶ $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - w_1 x_i - w_0)^2$
- ▶ $\frac{\partial J}{\partial w_0} = [\frac{1}{2n} 2 \sum_{i=1}^n e_i](-1)$
 - ▶ $w_0 = w_0 + \alpha \frac{1}{n} \sum_{i=1}^n e_i$
- ▶ $\frac{\partial J}{\partial w_1} = [\frac{1}{2n} 2 \sum_{i=1}^n (y_i - w_1 x_i - w_0)](-x_i)$



Gradiente Descendente

- ▶ $w = w - \alpha \frac{\partial J}{\partial w}$
- ▶ $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - w_1 x_i - w_0)^2$
- ▶ $\frac{\partial J}{\partial w_0} = [\frac{1}{2n} 2 \sum_{i=1}^n e_i](-1)$
 - ▶ $w_0 = w_0 + \alpha \frac{1}{n} \sum_{i=1}^n e_i$
- ▶ $\frac{\partial J}{\partial w_1} = (\frac{1}{2n} 2 \sum_{i=1}^n e_i)(-x_i)$



Gradiente Descendente

- ▶ $w = w - \alpha \frac{\partial J}{\partial w}$
- ▶ $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - w_1 x_i - w_0)^2$
- ▶ $\frac{\partial J}{\partial w_0} = [\frac{1}{2n} 2 \sum_{i=1}^n e_i](-1)$
 - ▶ $w_0 = w_0 + \alpha \frac{1}{n} \sum_{i=1}^n e_i$
- ▶ $\frac{\partial J}{\partial w_1} = (\frac{1}{2n} 2 \sum_{i=1}^n e_i)(-x_i)$
 - ▶ $w_1 = w_1 + \alpha \frac{1}{n} \sum_{i=1}^n e_i x_i$



Gradiente Descendente

- ▶ Regressão Linear Univariada

- ▶ $w_0 = w_0 + \alpha \frac{1}{n} \sum_{i=1}^n e_i$

- ▶ $w_1 = w_1 + \alpha \frac{1}{n} \sum_{i=1}^n e_i x_i$



Gradiente Descendente

- ▶ Define α pequeno
- ▶ Utiliza todo o conjunto de dados e atualiza os pesos
 - ▶ $w_0 = w_0 + \alpha \frac{1}{n} \sum_{i=1}^n e_i$
 - ▶ $w_1 = w_1 + \alpha \frac{1}{n} \sum_{i=1}^n e_i x_i$
- ▶ Repete o procedimento diversas vezes (épocas)



Gradiente Descendente Estocástico

- ▶ Atualização a cada amostra



Gradiente Descendente Estocástico

- ▶ Atualização a cada amostra

- ▶ $w_0 = w_0 + \alpha e_i$

- ▶ $w_1 = w_1 + \alpha e_i x_i$



Gradiente Descendente Estocástico

- ▶ Define α pequeno
- ▶ Utiliza todo o conjunto de dados e atualiza os pesos
 - ▶ $w_0 = w_0 + \alpha e_i$
 - ▶ $w_1 = w_1 + \alpha e_i x_i$
- ▶ Faz permutação nos dados
- ▶ Repete o procedimento diversas vezes (épocas)



Regressão Linear Multivariada

Regressão Linear Multivariada

- ▶ Em diversos problemas é necessário utilizar mais de uma variável x para tentar explicar a variável de saída y



Regressão Linear Multivariada

- ▶ Em diversos problemas é necessário utilizar mais de uma variável x para tentar explicar a variável de saída y
 - ▶ Exemplo
 - ▶ Concessão de crédito



Regressão Linear Multivariada

- ▶ Em diversos problemas é necessário utilizar mais de uma variável x para tentar explicar a variável de saída y
 - ▶ Exemplo
 - ▶ Concessão de crédito

Salário (R\$)	Dívida (R\$)	Crédito (R\$)
1500	0	16500
2000	4000	12000
3000	2000	28000
...		...
5500	1700	52000



Regressão Linear Multivariada

► Concessão de Crédito

- Encontrar uma relação linear entre Salário, Dívida e Crédito
- Salário (x_{1i}), Dívida (x_{2i}) e Crédito (y_i)
- $\bar{y}_i = w_1 x_{1i} + w_2 x_{2i} + w_0$

Salário (R\$)	Dívida (R\$)	Crédito (R\$)
1500	0	16500
2000	4000	12000
3000	2000	28000
...		...
5500	1700	52000



Regressão Linear Multivariada

► $\bar{y}_i = w_1x_{1i} + w_2x_{2i} + w_0$

Salário (R\$)	Dívida (R\$)	Crédito (R\$)
1500	0	16500
2000	4000	12000
3000	2000	28000



Regressão Linear Multivariada

- ▶ $\bar{y}_i = w_1x_{1i} + w_2x_{2i} + w_0$
- ▶ $\bar{y}_i = w_1x_{1i} + w_2x_{2i} + w_0x_0$
 - ▶ $x_0 = 1$

Salário (R\$)	Dívida (R\$)	Crédito (R\$)
1500	0	16500
2000	4000	12000
3000	2000	28000



Regressão Linear Multivariada

- ▶ $\bar{y}_i = w_1 x_{1i} + w_2 x_{2i} + w_0$
- ▶ $\bar{y}_i = w_1 x_{1i} + w_2 x_{2i} + w_0 x_0$
 - ▶ $x_0 = 1$
- ▶ $\bar{y}_i = \mathbf{w}^T \mathbf{x}_i$

Salário (R\$)	Dívida (R\$)	Crédito (R\$)
1500	0	16500
2000	4000	12000
3000	2000	28000



Regressão Linear Multivariada

- ▶ $\bar{y}_i = \mathbf{w}^T \mathbf{x}_i$
 - ▶ $\mathbf{x}_1 = [1 \ 1500 \ 0]^T, \mathbf{x}_2 = [1 \ 2000 \ 4000]^T, \dots$
 - ▶ $\mathbf{w}^T = [w_0 \ w_1 \ w_2]$

Salário (R\$)	Dívida (R\$)	Crédito (R\$)
1500	0	16500
2000	4000	12000
3000	2000	28000



Regressão Linear Multivariada

- ▶ $\bar{y}_i = \mathbf{w}^T \mathbf{x}_i$
- ▶ Para aprender os pesos, pode-se utiliza o gradiente descendente de forma semelhante à apresentada anteriormente.



Gradiente Descendente

- ▶ Regressão Linear Multivariada

- ▶ $\bar{y}_i = \mathbf{w}^T \mathbf{x}_i$

- ▶ Regra de Aprendizado

- ▶ $\mathbf{w} = \mathbf{w} + \alpha \frac{1}{n} \sum_{i=1}^n e_i \mathbf{x}_i$



Gradiente Descendente Estocástico

- ▶ Regressão Linear Multivariada

- ▶ $\bar{y}_i = \mathbf{w}^T \mathbf{x}_i$

- ▶ Regra de Aprendizado

- ▶ $\mathbf{w} = \mathbf{w} + \alpha e_i \mathbf{x}_i$



Regressão Linear (em lote - *batch*)

- ▶ Se já tivermos todos os pontos, é possível calcular os parâmetros sem utilizar um processo iterativo.



Regressão Linear (em lote - *batch*)

- ▶ Se já tivermos todos os pontos, é possível calcular os parâmetros sem utilizar um processo iterativo.
- ▶ Exemplo
 - ▶ $\bar{y}_i = w^T x_i$

Salário (R\$)	Dívida (R\$)	Crédito (R\$)
1500	0	16500
2000	4000	12000
3000	2000	28000

Regressão Linear (em lote - *batch*)

- ▶ Se já tivermos todos os pontos, é possível calcular os parâmetros sem utilizar um processo iterativo.
- ▶ Exemplo
 - ▶ $\bar{y}_i = \mathbf{w}^T \mathbf{x}_i$
 - ▶ $\mathbf{Y} = [y_1 \ y_2 \ \dots \ y_n]^T$

Salário (R\$)	Dívida (R\$)	Crédito (R\$)
1500	0	16500
2000	4000	12000
3000	2000	28000

Regressão Linear (em lote - *batch*)

- ▶ Se já tivermos todos os pontos, é possível calcular os parâmetros sem utilizar um processo iterativo.
- ▶ Exemplo
 - ▶ $\bar{y}_i = \mathbf{w}^T \mathbf{x}_i$
 - ▶ $\mathbf{Y} = [y_1 \ y_2 \ \dots \ y_n]^T$
 - ▶ $\mathbf{Y} = [16500 \ 12000 \ 2800]^T$

Salário (R\$)	Dívida (R\$)	Crédito (R\$)
1500	0	16500
2000	4000	12000
3000	2000	28000

Regressão Linear (em lote - *batch*)

- ▶ Se já tivermos todos os pontos, é possível calcular os parâmetros sem utilizar um processo iterativo.
- ▶ Exemplo
 - ▶ $\bar{y}_i = \mathbf{w}^T \mathbf{x}_i$
 - ▶ $\mathbf{Y} = [y_1 \ y_2 \ \dots \ y_n]^T$
 - ▶ $\mathbf{X} = [\mathbf{x}_1 \ \mathbf{x}_2 \ \dots \ \mathbf{x}_n]^T$

Salário (R\$)	Dívida (R\$)	Crédito (R\$)
1500	0	16500
2000	4000	12000
3000	2000	28000

Regressão Linear (em lote - *batch*)

- ▶ Se já tivermos todos os pontos, é possível calcular os parâmetros sem utilizar um processo iterativo.

- ▶ Exemplo

- ▶ $\bar{y}_i = \mathbf{w}^T \mathbf{x}_i$

- ▶ $\mathbf{Y} = [y_1 \ y_2 \ \dots \ y_n]^T$

- ▶ $\mathbf{X} = [\mathbf{x}_1 \ \mathbf{x}_2 \ \dots \ \mathbf{x}_n]^T$

- ▶ $\mathbf{X} = \begin{bmatrix} 1 & 1500 & 0 \\ 1 & 2000 & 4000 \\ 1 & 3000 & 2000 \end{bmatrix}$

Salário (R\$)	Dívida (R\$)	Crédito (R\$)
1500	0	16500
2000	4000	12000
3000	2000	28000

Regressão Linear (em lote - *batch*)

- ▶ Modelo

- ▶ $\bar{Y} = Xw$



Regressão Linear (em lote - *batch*)

- ▶ Modelo

- ▶ $\bar{Y} = X\mathbf{w}$

- ▶ Função de custo

- ▶ $J(\mathbf{w}) = \frac{1}{2} (Y - \bar{Y})^T (Y - \bar{Y})$

- ▶ $J(\mathbf{w}) = \frac{1}{2} (Y - X\mathbf{w})^T (Y - X\mathbf{w})$



Regressão Linear (em lote - *batch*)

- ▶ Modelo

- ▶ $\bar{Y} = X\mathbf{w}$

- ▶ Função de custo

- ▶ $J(\mathbf{w}) = \frac{1}{2} (Y - \bar{Y})^T (Y - \bar{Y})$

- ▶ $J(\mathbf{w}) = \frac{1}{2} (Y - X\mathbf{w})^T (Y - X\mathbf{w})$

- ▶ Minimizando J (derivando e igualando a zero)



Regressão Linear (em lote - *batch*)

- ▶ Modelo

- ▶ $\bar{Y} = X\mathbf{w}$

- ▶ Função de custo

- ▶ $J(\mathbf{w}) = \frac{1}{2} (Y - \bar{Y})^T (Y - \bar{Y})$

- ▶ $J(\mathbf{w}) = \frac{1}{2} (Y - X\mathbf{w})^T (Y - X\mathbf{w})$

- ▶ Minimizando J (derivando e igualando a zero)

- ▶ $\frac{\partial J}{\partial \mathbf{w}} = \frac{1}{2} 2(-X^T)(Y - X\mathbf{w}) = 0$



Regressão Linear (em lote - *batch*)

- ▶ Modelo

- ▶ $\bar{Y} = X\mathbf{w}$

- ▶ Função de custo

- ▶ $J(\mathbf{w}) = \frac{1}{2} (Y - \bar{Y})^T (Y - \bar{Y})$

- ▶ $J(\mathbf{w}) = \frac{1}{2} (Y - X\mathbf{w})^T (Y - X\mathbf{w})$

- ▶ Minimizando J (derivando e igualando a zero)

- ▶ $\frac{\partial J}{\partial \mathbf{w}} = \frac{1}{2} 2(-X^T)(Y - X\mathbf{w}) = 0$

- ▶ $X^T X\mathbf{w} = X^T Y$



Regressão Linear (em lote - *batch*)

- ▶ Modelo

- ▶ $\bar{Y} = X\mathbf{w}$

- ▶ Função de custo

- ▶ $J(\mathbf{w}) = \frac{1}{2} (Y - \bar{Y})^T (Y - \bar{Y})$

- ▶ $J(\mathbf{w}) = \frac{1}{2} (Y - X\mathbf{w})^T (Y - X\mathbf{w})$

- ▶ Minimizando J (derivando e igualando a zero)

- ▶ $\frac{\partial J}{\partial \mathbf{w}} = \frac{1}{2} 2(-X^T)(Y - X\mathbf{w}) = 0$

- ▶ $X^T X\mathbf{w} = X^T Y$

- ▶ $\mathbf{w} = (X^T X)^{-1} X^T Y$



Regressão Linear (em lote - *batch*)

- ▶ Modelo
 - ▶ $\bar{Y} = Xw$
- ▶ Regra de Aprendizado
 - ▶ $w = (X^T X)^{-1} X^T Y$

Método dos mínimos quadrados





Dúvidas ?