

# Aprendizagem Automática


João Paulo Pordeus Gomes



# Support Vector Machines


# SVM

---




# SVM

---




# SVM

---




# SVM

---



# SVM

---



# SVM


---

## ► Problema

►  $\min \frac{1}{2} w^T w$

s.t

$$y_i(w^T x_i + b) \geq 1$$





# SVM


---

## ► Problema

►  $\min \frac{1}{2} w^T w$

s.t

$$y_i(w^T x_i + b) \geq 1 - \xi_i$$



# SVM (Soft Margin)


---

## ► Problema

►  $\min \frac{1}{2} w^T w + C \sum_{i=1}^n \xi_i$

s.t

$$y_i(w^T x_i + b) \geq 1 - \xi_i$$



# Support Vector Machines

---

- ▶ **Parâmetro C**
  - ▶ Seleciona o grau de ajuste do modelo aos dados de treinamento.
    - ▶ Overfitting



# Support Vector Machines

---

- ▶ Até agora
  - ▶ SVM linear
  - ▶ Dados linearmente separáveis
- ▶ Versão não linear ?



# Support Vector Machines

---

- ▶ Até agora
  - ▶ SVM linear
  - ▶ Dados linearmente separáveis
- ▶ Versão não linear ?
  - ▶ Kernel trick



# Kernel Trick

---

- ▶ Como transformar um classificador linear em não linear ?



# Kernel Trick

---

- ▶ Como transformar um classificador linear em não linear ?
- ▶ Criar novos atributos de forma não linear
  - ▶  $x = [x_1 \ x_2]$ 
    - ▶  $x_3 = x_1^2 + x_2^2$
  - ▶  $x = [x_1 \ x_2 \ x_3]$



# Kernel Trick

---

- ▶ Usando SVM

- ▶  $w = \sum_i \alpha_i y_i x_i$

- ▶  $y_i(w^T x_i + b) \geq 1$

- ▶  $\bar{y}_j = g(w^T x_j + b)$

- $\bar{y}_i = +1$  ou  $-1$





# Kernel Trick

---

- ▶ Usando SVM

- ▶  $w = \sum_i \alpha_i y_i x_i$

- ▶  $y_i(w^T x_i + b) \geq 1$

- ▶  $\bar{y}_j = (\sum_i \alpha_i y_i x_i^T x_j + b)$

- $\bar{y}_i = +1$  ou  $-1$



# Aumentando a dimensão

---

- ▶ Exemplo

- ▶  $x = [x_1 \ x_2]$



# Aumentando a dimensão

---

- ▶ Exemplo

- ▶  $x = [x_1 \ x_2]$

- ▶  $x^a = [x_1^2 \ \sqrt{2}x_1x_2 \ x_2^2]$



# Aumentando a dimensão

---

- ▶ Exemplo

- ▶  $x = [x_1 \ x_2]$

- ▶  $x^a = [x_1^2 \ \sqrt{2}x_1x_2 \ x_2^2]$

- ▶ Do SVM

- ▶  $\bar{y}_j = (\sum_i \alpha_i y_i x_i^T x_j + b)$



# Aumentando a dimensão

---

- ▶ Exemplo

- ▶  $x = [x_1 \ x_2]$

- ▶  $x^a = [x_1^2 \ \sqrt{2}x_1x_2 \ x_2^2]$

- ▶ O produto interno entre dois vetores aumentados:

- ▶  $x^{aT} z^a = [x_1^2 \ \sqrt{2}x_1x_2 \ x_2^2] [z_1^2 \ \sqrt{2}z_1z_2 \ z_2^2]^T$



# Aumentando a dimensão

---

- ▶ Exemplo

- ▶  $x = [x_1 \ x_2]$

- ▶  $x^a = [x_1^2 \ \sqrt{2}x_1x_2 \ x_2^2]$

- ▶ O produto interno entre dois vetores aumentados:

- ▶  $x^{aT} z^a = [x_1^2 \ \sqrt{2}x_1x_2 \ x_2^2] [z_1^2 \ \sqrt{2}z_1z_2 \ z_2^2]^T$

- ▶  $x^{aT} z^a = x_1^2 z_1^2 + 2x_1x_2 z_1z_2 + x_2^2 z_2^2$



# Aumentando a dimensão

---

- ▶ Exemplo

- ▶  $x = [x_1 \ x_2]$

- ▶  $x^a = [x_1^2 \ \sqrt{2}x_1x_2 \ x_2^2]$

- ▶ O produto interno entre dois vetores aumentados:

- ▶  $x^{aT} z^a = [x_1^2 \ \sqrt{2}x_1x_2 \ x_2^2] [z_1^2 \ \sqrt{2}z_1z_2 \ z_2^2]^T$

- ▶  $x^{aT} z^a = x_1^2 z_1^2 + 2x_1x_2z_1z_2 + x_2^2 z_2^2$

- ▶  $x^{aT} z^a = \{[x_1 \ x_2]^T [z_1 \ z_2]\}^2$



# Aumentando a dimensão

---

- ▶  $x^{aT} z^a = \{[x_1 \ x_2]^T [z_1 \ z_2]\}^2$
- ▶  $x^{aT} z^a = f(x, z)$





# Aumentando a dimensão

---


- ▶  $x^{aT} z^a = \{[x_1 \ x_2]^T [z_1 \ z_2]\}^2$
- ▶  $x^{aT} z^a = f(x, z)$
- ▶  $f$  é uma função de Kernel
  - ▶  $x^{aT} z^a = K(x, z)$



# Aumentando a dimensão

---


## ► Estratégia convencional




# Aumentando a dimensão

---

## ► Estratégia convencional



## ► Com Kernel



# SVM com Kernel

---

- ▶ Usando SVM

- ▶  $\bar{y}_j = \sum_i \alpha_i y_i x_i^T x_j + b$

- $\bar{y}_i = +1$  ou  $-1$



# SVM com Kernel

---

- ▶ Usando SVM
- ▶  $\bar{y}_j = \sum_i \alpha_i y_i K(x_i^T x_j) + b$ 
  - $\bar{y}_i = +1$  ou  $-1$



# Funções Kernel

---

$$K(\vec{x}_i, \vec{x}_j) = \vec{x}_i \cdot \vec{x}_j$$

Linear kernel

$$K(\vec{x}_i, \vec{x}_j) = \exp(-\gamma \|\vec{x}_i - \vec{x}_j\|^2)$$

Gaussian kernel

$$K(\vec{x}_i, \vec{x}_j) = \exp(-\gamma \|\vec{x}_i - \vec{x}_j\|)$$

Exponential kernel

$$K(\vec{x}_i, \vec{x}_j) = (p + \vec{x}_i \cdot \vec{x}_j)^q$$

Polynomial kernel

$$K(\vec{x}_i, \vec{x}_j) = (p + \vec{x}_i \cdot \vec{x}_j)^q \exp(-\gamma \|\vec{x}_i - \vec{x}_j\|^2)$$

Hybrid kernel

$$K(\vec{x}_i, \vec{x}_j) = \tanh(k\vec{x}_i \cdot \vec{x}_j - \delta)$$

Sigmoidal



# Funções Kernel mais Comuns

---

- ▶  $K(x, y) = \exp\left(\frac{(x-y)^T(x-y)}{\sigma^2}\right)$
- ▶  $K(x, y) = (p + x^T y)^q$



# Support Vector Machines

---

- ▶ **Parâmetro C**
  - ▶ Seleciona o grau de ajuste do modelo aos dados de treinamento.
- ▶ **Parâmetro do Kernel ( $\sigma^2$ , p,q ...)**
  - ▶ Seleciona a complexidade da superfície de decisão





# Support Vector Machines

---

- ▶ Seleção dos Hiper-parâmetros
  - ▶ Validação Cruzada



# Support Vector Machines

---

- ▶ Seleção dos Hiper-parâmetros
  - ▶ Validação Cruzada
- ▶ Classificação Multiclasse
  - ▶ 1 contra todos





Dúvidas ?